

Pro. 多元统计分析

指导教师: 李野

仓库地址: https://github.com/DGMEFG/anime\_cls

# 基于 GochiUsa Faces 数据集分类问题的解决方案

⑩ 沈运之

● 黄开奕

命

052110814

182111510

082120109

1729990469@qq.com

1476060622@qq.com

1928161381@qq.com

December 20, 2023

 Keywords:
 图像分类 降维 判别 多因变变量线性回
 DANBOORU 包含 9141 张图片,初始文件夹里

 归假设检验
 包含 (通道数为 3) 从 26 × 26,到 987 × 987 尺

# 1. 介绍

## 1.1. 概要

统计学习中,分类问题应该算得上是一个相当经典的模型,大多数方法都可以参与这一问题的解决,基于此,用分类问题来应用多元统计分析所学到的知识再合适不过。

分类问题中,图像分类占据了很大程度的一部分,然后,现实中的图片分类问题要经过传感器获取,以及 Jpeg 压缩一系列退化的过程,其一般受噪声影响较为严重,所以我们选择了产生于互联网上的图片,即动漫人物的图片构建我们的分类问题 (其实单纯是因为兴趣)。

该图片数据集主要由两个文件夹构成,ANIME 文件夹用于训练,DANBOORU 文件夹用于测试,其中包含 9 个类别,分别是 Blue Mountain,Chino,Chiya,Cocoa,Maya,Megumi,Mocha,Rize,Sharo 对应数字 0-8; ANIME 包含 59579 张图片,

DANBOORU 包含 9141 张图片,初始文件夹里包含 (通道数为 3) 从 26 × 26,到 987 × 987 尺寸不一的图片,为了便于处理,已经经过 python 脚本统一处理为 32 × 32。原数据集来源于 Kag-gle:https://www.kaggle.com/datasets/rignak/gochiusa-faces。

## 1.2. 解决方案

首先我们小组成员自行充当分类器,分类效果非常好,因此这个学习问题是理论上可以实现。下面我将阐述这份实验提供的解决方案:

#### Note:

- 首先观察图片数据的特征是否近似满足 正态分布,以及初步构建对于数据认识。
- 然后基于先验,选择合适的方法进行降维, 并将降至二维进行可视化。
- 对于不同的降维结果,使用基于模型的多 因变量的线性回归, SVM, 以及 modelfree 的基于决策树的分类器进行测试,挑

选出最好的结果。

• 基于以上结果进行分析。

## 1.3. 符号约定

为了便于叙述,这里规定 N 为数据集样本数,M 为每个样本的特征,这里定义每个样本的特征为图片 张量向量化的结果,X 为  $N\times M$  的数据矩阵,Y 为  $N\times 1$  的标签向量,其中  $y_i\in Z$  and  $y_i\in [0,8]$ ,约定每一个样本为  $X_i^\top=\begin{bmatrix}x_{i1}&\cdots&x_{iM}\end{bmatrix}$ ,对应标签为  $y_i$ , $Y=\begin{bmatrix}y_1&y_2&\cdots&y_N\end{bmatrix}^\top$  从而有:

$$X = \begin{bmatrix} X_1^\top \\ X_2^\top \\ \vdots \\ X_N^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1M} \\ x_{21} & x_{22} & \cdots & x_{2M} \\ \vdots & & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{NM} \end{bmatrix}$$

# 2. 数据属性

在对数据进行进一步分析,为了尽可能防止出现数值问题 (0-255 以内的数字多次线性组合可能会是很大的值),首先先将数据通过标准化处理调整为均值为 0,方差为 1,设  $\bar{x}_i$  为数据矩阵 X 第 i 列的样本均值 (也就是随机变量  $X_i$  的 N 次取样), $\sigma_i$  为其标准差,于是其内的数据 x 的标准化后的值  $\tilde{x}$  为:

$$\tilde{x} = \frac{x - \bar{x}_i}{\sigma_i}$$

# 2.1. 类别情况

首先观察最直观的数据属性,将每个类别在训练集和测试集上的规模画出 (见 Figure 1),训练集内最少的两个类别为 Mocha 与 Blue Mountain 分别有1241个,1607个,而数量最多的类别 Chino 有12941个,倍数达到十倍,该数据集为长尾数据集,原数据集作者说,大部分角色具有明显的特征,因此我们仍然选择这两个类别作为我们分类任务的一环 (本质上还是因为这个学习问题不太难)。

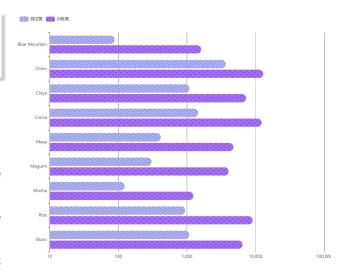


Figure 1: 各类别训练集与测试集的分类情况,横轴 为类别对应的样本数目,且采用对数刻度

## 2.2. Subsección

## 2.2.1. Subsubsección

Definición 1 (Nombre de la definición) Sea f ...

#### Definición 2

Definición sin nombre ...

Ejemplo para hacer referencia a una definición (teorema, corolario, etc), en la definición 2.

#### Notación 1

Notación sin nombre ...

#### Teorema 1 (Nombre del teorema)

Sea  $f \dots$ 

Proof. Prueba de teorema

### Teorema 2

Teorema sin nombre ...

2.2 Subsección 3

#### En el teorema 1

## Ejemplo 1 (Nombre del ejemplo)

Sea f ...

## Ejemplo 2

Ejemplo sin nombre ...

Corolario 1 Sea f ...

Corolario 2 Corolario sin nombre ...

Lema 1 (Nombre del lema) Sea f ...

Lema 2 Lema si nombre ...

Note: (Nombre de la nota) Sea f ...

Note: Nota sin nombre ...

Vocabulario 1 (Nombre del vocabulario) Sea f ...

Vocabulario 2 Vocabulario sin nombre ...

### Algoritmo 1 (Nombre del algoritmo)

Algoritmo con nombre ...

#### Observación 1

Observación sin nombre ...

(Nombre de la caja)

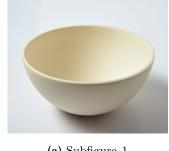
Sea f ...

Scaja sin nombre ...



Figure 2: Título de la figura. Decir si es elaboración propia referencia.

Note cómo en la Figura 2 ...





(a) Subfigura 1

(b) Subfigura 2

Figure 3: Título para la figura en general. Decir si es elaboraci o poner referencia.

En la Figura 3, en la subfigura 3b se observa que ...

Puede observar en la Tabla 1 ...

Table 1: Título de la Tabla. Decir si es elaboración propia o po encia.

$\overline{name}$	foo			
Models	A	В	С	D
$\mathrm{Model}\ X$	X1	X2	X3	X4
$\mathrm{Model}\ Y$	Y1	Y2	<b>Y</b> 3	Y4

Ecuación numerada:

$$x = \frac{b \pm \sqrt{b^2 - 4ac}}{2a} \tag{1}$$

BIBLIOGRAPHY 4

En la fórmula 1 ...

Ecuación no numerada:

$$x = \frac{b \pm \sqrt{b^2 - 4ac}}{2a}$$

Ecuación alineada numerada:

$$x = a^2 - b^2 \tag{2}$$

$$= (a-b)(a+b) \tag{3}$$

En las expresiones 2 y 3 ...

Ecuación alineada no numerada:

$$x = a^2 - b^2$$
$$= (a - b)(a + b)$$

Ecuación centrada

$$a^2 = b^2 + c^2$$

Ejemplo de código Java:

```
/**
* This is a doc comment.
*/
package
   com.ociweb.jnb.lombok;
```

```
import lombok.Data;
import
```

import java.util.Date;

lombok.EqualsAndHashCode; import lombok.NonNull;

```
public class Person {
        enum Gender { Male,
           Female }
        // another comment
```

String lastName;

```
@NonNull private
   String firstName;
@NonNull private
```

```
@NonNull private
   final Gender
   gender;
@NonNull private
   final Date
   dateOfBirth;
```

```
private String ssn;
        private String
           address;
        private String city;
        private String state;
        private String zip;
}
```

Este es código en la misma línea import java.util.Date;, el símbolo | es sólo un delimitador y se puede cambiar por algún otro que no se utilice en el código.

Esta es una cita de la bibliografía: [1]

La bibliografía se prefiere según APA con utilizando biblatex con Biber, también aceptamos el formato IEEE.

#### 3. **Bibliography**

[1] Cita H

# A. Apéndice

```
@EqualsAndHashCode(exclude={"address","city","state","zip"})
                                Apéndice
```